



گزارش پروژه ی درس یادگیری ماشین

تابستان ۱۴۰۴

امیرعلی جعفری - ۴۰۰۱۰۰۹۳۸

عرفان باطنی - ۴۰۰۱۰۰۷۹۲

فهرست

1- Introduction

2- Bayesian Linear Regression

3- Bayesian Deep Learning via Dropout (Bonus)

4- Bayesian Neural Network via MCMC

5- Hamiltonian Monte Carlo (HMC)

6- Conclusion

1- Introduction:

در بسیاری از مسائل علمی و داده‌محور، مدل‌سازی پیش‌بینی با نوعی عدم قطعیت و پیچیدگی همراه است. روش‌های کلاسیک که معمولاً بر پایه‌ی یک جواب قطعی عمل می‌کنند، توانایی محدودی در توضیح این عدم قطعیت دارند و گاهی نتایج آن‌ها بیش از حد مطمئن به نظر می‌رسد. در مقابل، رویکرد بیزین با استفاده از توزیع‌های احتمالی به جای نقطه‌ی تخمین، امکان درک بهتر از تغییرپذیری داده‌ها و نتایج مدل را فراهم می‌کند. این تغییر دیدگاه باعث می‌شود تحلیل‌ها واقع‌بینانه‌تر شوند و تصمیم‌گیری‌ها بر پایه‌ی عدم قطعیت‌های موجود شکل بگیرند.

یکی از مهم‌ترین دلایل استفاده از روش‌های بیزین، توانایی آن‌ها در مدیریت و کمی‌سازی انواع مختلف عدم قطعیت است. برای مثال، عدم قطعیت دانشی که ناشی از کمبود داده یا محدودیت مدل است، با افزودن داده‌های جدید یا بهبود مدل قابل کاهش می‌باشد و روش بیزین به خوبی آن را بازتاب می‌دهد. از سوی دیگر، ابهام یا عدم قطعیت ساختاری که به دلیل وجود چند مدل رقیب یا تعریف‌های مبهم از مسئله ایجاد می‌شود، با مقایسه مدل‌ها یا ترکیب چند مدل در بیزین تا حدی قابل بررسی است. در مجموع، این روش‌ها باعث می‌شوند تحلیل‌ها شفاف‌تر شده و نتایج نهایی بر پایه‌ی درک درست‌تری از پیچیدگی‌های دنیای واقعی بنا شوند.


2- Bayesian Linear Regression

برای پیش‌بینی عملکرد تحصیلی دانش‌آموزان، ابتدا داده‌های مربوط به دانش‌آموزان یک دبیرستان پرتغالی مورد بررسی قرار گرفت. متغیر هدف در این مجموعه داده، نمره نهایی (G3) است که مقداری بین ۱ تا ۲۰ دارد. در مرحله پیش‌پردازش، نمونه‌هایی که نمره نهایی آن‌ها صفر بود حذف شدند، چرا که احتمال می‌رفت این داده‌ها ناقص یا خارج از حوزه مسئله باشند.

آمار توصیفی نمرات نهایی نشان می‌دهد که تعداد نمونه‌ها ۶۳۴ دانش‌آموز است، میانگین نمره ۱۲.۱۹ و انحراف معیار ۲.۶۹ است. این مقادیر نشان می‌دهند که نوسان نمرات نسبتاً کم است و بیشتر دانش‌آموزان نزدیک میانگین قرار دارند. محدوده نمرات تقریباً کامل (۱ تا ۱۹) است و چارک‌ها نشان می‌دهند که یک‌چهارم دانش‌آموزان نمره ≥ 10 ، میانه برابر ۱۲ و سه‌چهارم نمره ≥ 14 دارند.

هیستوگرام نمرات نهایی نشان می‌دهد که اکثر دانش‌آموزان بین ۱۰ تا ۱۴ نمره کسب کرده‌اند و تعداد کمی نمرات بسیار پایین یا بسیار بالا دارند. این توزیع تقریباً نرمال با کمی کشیدگی سمت راست است، بنابراین مدل‌های رگرسیون خطی و به‌ویژه Bayesian Linear Regression می‌توانند عملکرد مناسبی داشته باشند. داده‌ها پاکسازی شده و ویژگی‌ها آماده محاسبه همبستگی با G3 و انتخاب پنج ویژگی اصلی هستند تا مراحل بعدی مدل‌سازی انجام شود.


Histogram of final grades



برای آماده‌سازی داده‌ها جهت مدل‌سازی، ابتدا متغیر هدف یعنی نمره نهایی دانش‌آموزان (G3) جدا شد و ستون‌هایی که نباید به عنوان ویژگی استفاده شوند، حذف شدند. این ستون‌ها شامل شناسه مدرسه (school) و نمرات قبلی (G1 و G2) بودند تا از نشت اطلاعات به مدل جلوگیری شود. سپس برای متغیرهای دسته‌ای، کدگذاری «one-hot» انجام شد تا آن‌ها به فرمت عددی مناسب برای مدل‌های خطی تبدیل شوند.

پس از کدگذاری، متغیر هدف دوباره به عنوان ستون y به دیتافریم اضافه شد تا بتوان همبستگی هر ویژگی با هدف را محاسبه کرد. ویژگی‌هایی که همبستگی مطلق آن‌ها با نمره نهایی کمتر از ۰.۲ بود حذف شدند تا نویز از داده‌ها کاهش یابد و تنها مهم‌ترین متغیرها باقی بمانند. در این مرحله همچنین ستون تکراری higher_no حذف شد و فقط higher_yes نگه داشته شد تا داده‌ها منسجم و بدون همپوشانی باشند.

در نهایت، داده‌ها به دو مجموعه آموزش و آزمون با نسبت ۲۵/۷۵ تقسیم شدند تا مدل بتواند ابتدا روی داده‌های آموزش یاد بگیرد و سپس عملکرد آن روی داده‌های جدید سنجیده شود. ستون higher_yes نیز به نوع عددی (۱/۰) تبدیل شد تا با مدل‌های رگرسیون خطی سازگار باشد. نتیجه، مجموعه‌ای از پنج ویژگی انتخاب شده شامل Dalc، failures، studytime، Medu و higher_yes است که آماده آموزش مدل می‌باشند.



در نمودار حاصل از کد بالا، رابطه میان ویژگی‌های انتخاب‌شده و نمره نهایی به صورت جفت‌جفت نمایش داده شده است. در قطر نمودار، هیستوگرام هر ویژگی نشان داده می‌شود که توزیع داده‌ها را نشان می‌دهد. برای مثال، می‌توان دید که ویژگی‌هایی مانند **studytime** و **Medu** دارای توزیع نسبتاً یکنواخت هستند، در حالی که ویژگی‌هایی مانند **failures** یا



Dalc بیشتر داده‌ها را در مقادیر پایین متمرکز کرده‌اند. این اطلاعات اولیه به ما کمک می‌کند تا الگوهای توزیع داده‌ها را قبل از آموزش مدل بهتر درک کنیم.

در قسمت پایین مثلث، همبستگی پیرسون بین هر جفت ویژگی و همچنین با نمره نهایی نمایش داده شده است. مقادیر عددی نشان می‌دهند که برخی ویژگی‌ها مانند `studytime` و `failures` همبستگی منفی و مثبت قابل توجهی با نمره نهایی دارند، به طوری که افزایش `failures` معمولاً با کاهش نمره نهایی همراه است و افزایش `studytime` با افزایش نمره نهایی. این همبستگی‌ها به ما نشان می‌دهد که ویژگی‌های انتخاب شده توانایی توضیح بخش قابل توجهی از تغییرات نمره نهایی را دارند و می‌توانند به عنوان ورودی‌های مؤثر برای مدل رگرسیون خطی و Bayesian Linear Regression استفاده شوند.

نمودار اول نشان می‌دهد که مدل‌های درختی مانند Random Forest و Extra Trees کمترین RMSE را دارند و بنابراین دقیق‌ترین پیش‌بینی‌ها را ارائه می‌کنند، در حالی که مدل‌های خطی مانند Linear Regression و ElasticNet خطای بیشتری دارند.


در نمودار دوم (MAPE)، روند مشابهی دیده می‌شود: مدل‌های درختی درصد خطای نسبی کمتری دارند و دقت بالاتری نسبت به مدل‌های خطی و SVM نشان می‌دهند.

Baseline با استفاده از میانه نمرات، بیشترین خطا را دارد که نشان می‌دهد استفاده از مدل‌های یادگیری ماشین باعث بهبود قابل توجهی در پیش‌بینی نمره نهایی دانش‌آموزان می‌شود.




نمودار trace که توسط ArviZ تولید شده است، هم روند نمونه‌گیری زنجیره‌های MCMC و هم توزیع پسین پارامترها را نمایش می‌دهد. نمودارهای خطی (trace lines) نشان می‌دهند که زنجیره‌ها به خوبی در فضای پارامترها کاوش کرده و با گذر زمان نوسان طبیعی دارند، بدون اینکه رفتار روندهای طولانی یا ایستایی شوند. این نشانه‌ای از همگرایی مناسب مدل و عملکرد موثر الگوریتم NUTS است.

هیستوگرام‌ها یا نمودارهای چگالی در همان نمودار، توزیع پسین هر پارامتر را نشان می‌دهند و امکان برآورد میانگین، میانه و بازه اطمینان را فراهم می‌کنند. این اطلاعات علاوه بر برآورد پارامترها، عدم قطعیت مرتبط با هر پارامتر را نیز نشان می‌دهد، که مزیتی مهم نسبت به مدل‌های خطی کلاسیک است و کمک می‌کند تصمیم‌گیری مبتنی بر داده با لحاظ کردن اطمینان و ریسک انجام شود.




نمودار Forest که تولید شده، نمای خلاصه‌ای از توزیع‌های پسین پارامترهای مدل را همراه با بازه‌های اعتباری ۹۵٪ (HDI) ارائه می‌دهد. این نمودار به سرعت نشان می‌دهد که کدام پارامترها دارای برآوردهای مطمئن و پایدار هستند و کدام پارامترها با عدم قطعیت بیشتری همراه‌اند، بدون نیاز به بررسی تک‌تک نمونه‌های MCMC.

پارامترهایی مانند `failures`، `higher_yes` و `studytime` بازه‌های باریک و متمرکزی دارند که نشان می‌دهد مدل در برآورد اثر این متغیرها بر نمره نهایی دانش‌آموزان بسیار مطمئن است. این امر حاکی از این است که تغییرات در این ویژگی‌ها به طور قابل پیش‌بینی با تغییرات در نمره نهایی مرتبط است و داده‌ها به اندازه کافی اطلاعات برای تخمین دقیق این اثرات فراهم کرده‌اند. در مقابل، پارامترهایی مانند `sigma` یا `Medu` بازه‌های گسترده‌تری دارند که بیانگر عدم قطعیت بیشتری در برآورد اثر واقعی آن‌هاست. این یعنی مدل نمی‌تواند با اطمینان کامل اثر دقیق این متغیرها را روی نمره نهایی تعیین کند و احتمالاً نیاز به داده‌های بیشتر یا مدل پیچیده‌تر برای کاهش این عدم قطعیت وجود دارد. به طور کلی، نمودار Forest یک ابزار قدرتمند برای خلاصه‌سازی اثرات پارامترها و میزان اطمینان مدل است.



نمودار توزیع پسین که تولید شده، نمایشی از چگالی احتمال برای هر پارامتر مدل ارائه می‌دهد. محور افقی مقادیر پارامتر و محور عمودی چگالی احتمال را نشان می‌دهد و بازه‌های اعتباری ۹۵٪ (HDI) با خطوط افقی مشخص شده‌اند. پارامترهایی که توزیع پسین باریک و متمرکز دارند، مانند `higher_yes` یا `failures`، نشان می‌دهند که مدل در برآورد اثر آن‌ها اطمینان بالایی دارد. در مقابل، پارامترهایی مثل `sigma` یا `Medu` که توزیع‌های گسترده‌تری دارند، عدم قطعیت بیشتری در برآورد اثر آن‌ها را نشان می‌دهند.




استفاده از کل توزیع پسین به جای تنها میانگین یا میانه، امکان لحاظ کردن عدم قطعیت در پیش‌بینی‌ها را فراهم می‌کند. به این معنا که به جای تولید یک مقدار نقطه‌ای، می‌توان بازه‌ای از مقادیر محتمل برای نمره نهایی دانش‌آموزان بر اساس توزیع پسین پارامترها به دست آورد. این کار باعث می‌شود پیش‌بینی‌ها واقع‌گرایانه‌تر باشند و امکان محاسبه احتمالات رویدادهای خاص (مثلاً نمره بالاتر از ۱۵) فراهم شود، که در تحلیل‌های آموزشی و تصمیم‌گیری‌های مبتنی بر داده اهمیت بالایی دارد.




در تحلیل نتایج به دست آمده از مدل خطی بیزی، ابتدا وزن‌های میانگین هر پارامتر بررسی شد. مقادیر منفی مانند Dalc و failures نشان می‌دهند که مصرف الکل و شکست‌های قبلی دانش‌آموزان رابطه‌ی منفی با نمره نهایی دارند. بالعکس، پارامترهایی مانند higher_yes، Medu و studytime با مقادیر مثبت اثر مثبتی روی نمره نهایی دارند، که بیانگر تأثیر مثبت انگیزه تحصیلی، تحصیلات مادر و زمان مطالعه بر عملکرد دانش‌آموزان است. ضریب Intercept نیز بیانگر پایه‌ی نمره است که بدون در نظر گرفتن متغیرهای دیگر تقریباً ۹.۶ نمره است.

با ارزیابی مدل بر روی داده‌های تست، RMSE برابر با ۲.۴۴۷ و MAPE برابر با ۰.۱۳۹۴ به دست آمد. RMSE پایین نشان می‌دهد که اختلاف بین نمرات پیش‌بینی شده و واقعی نسبتاً کم است، و MAPE حدود ۱۳.۹٪ خطای نسبی پیش‌بینی را نشان می‌دهد. این مقادیر بیانگر عملکرد قابل قبول مدل بیزی در مقایسه با مدل‌های سنتی است و نشان می‌دهد که با استفاده از توزیع‌های پسین، می‌توان پیش‌بینی‌های قابل اطمینان و نسبتاً دقیق برای نمره دانش‌آموزان داشت.

تصویر نمودار پراکندگی پیش‌بینی و مشاهدات نشان می‌دهد که مدل توانسته نقاط را به خوبی حول خط واقعی قرار دهد و عدم قطعیت زیادی در پیش‌بینی‌ها وجود ندارد. همچنین مقایسه RMSE و MAPE مدل بیزی با مدل‌های مرجع سنتی (مانند رگرسیون خطی، جنگل تصادفی و غیره) در نمودارهای میله‌ای نشان می‌دهد که مدل بیزی حداقل در برخی شاخص‌ها عملکرد رقابتی دارد و مزیت اصلی آن امکان تحلیل عدم قطعیت و بهره‌گیری از توزیع کامل پارامترها در پیش‌بینی‌ها است.




نمودار چگالی حاصل از پیش‌بینی مدل بیزی برای مشاهده‌ی جدید، توزیع احتمالی نمره نهایی دانش‌آموز را نشان می‌دهد. محور افقی مقدار برآورد نمره و محور عمودی چگالی احتمال است. شکل منحنی تقریباً به صورت یک توزیع نرمال متمرکز است که بیانگر تمرکز پیش‌بینی‌ها در بازه‌ای مشخص است. استفاده از تمامی نمونه‌های پسین باعث می‌شود به جای یک مقدار نقطه‌ای، بازه‌ای از مقادیر محتمل برای نمره دانش‌آموز ارائه شود که عدم قطعیت پیش‌بینی را به خوبی نمایش می‌دهد. این ویژگی یکی از مزایای اصلی مدل بیزی نسبت به مدل‌های سنتی است. آمارهای گزارش شده نیز این عدم قطعیت را تکمیل می‌کنند: میانه‌ی توزیع به عنوان مقدار پیش‌بینی مرکزی ارائه شده و بازه‌ی ۵ تا ۹۵ درصد نشان‌دهنده‌ی محدوده‌ی اطمینان ۹۰٪ برای نمره‌ی پیش‌بینی شده است. این بدان معناست که با توجه به عدم قطعیت پارامترها، احتمال بالایی وجود دارد که نمره واقعی دانش‌آموز در این بازه قرار گیرد. چنین تحلیلی به تصمیم‌گیرندگان اجازه می‌دهد نه تنها پیش‌بینی میانگین را ببینند بلکه دامنه‌ی قابل انتظار نتایج را نیز در نظر بگیرند و اقدامات آموزشی یا مشاوره‌ای را بر اساس آن برنامه‌ریزی کنند.



نمودار چگالی حاصل از پیش‌بینی مدل بیزی برای مشاهده‌ی جدید، که ویژگی‌های دانش‌آموز شامل تحصیلات مادر متوسط ($Medu=2$)، دو بار مردودی در کلاس‌ها ($failures=2$)، تمایل به ادامه تحصیل ($higher_yes=1$)، زمان مطالعه متوسط ($studytime=2$) و مصرف الکل متوسط ($Dalc=2$) است، نشان می‌دهد که توزیع پیش‌بینی‌ها به سمت مقادیر پایین‌تر متمرکز شده


است. این کاهش نسبت به مشاهده‌ی قبلی عمدتاً ناشی از اثر منفی مردودی‌ها و مصرف الکل است که وزن‌های منفی بالایی در مدل دارند. منحنی چگالی به شکل تقریباً نرمال و متقارن است و تمرکز آن نشان می‌دهد که پیش‌بینی‌های مدل حول یک بازه خاص متمرکز هستند، اما هنوز کمی عدم قطعیت وجود دارد.

آمارهای عددی نمودار نیز بازه‌ی عدم قطعیت را مشخص می‌کنند: میانه‌ی توزیع به عنوان مقدار مرکزی پیش‌بینی ارائه شده و بازه‌ی ۵ تا ۹۵ درصد نشان‌دهنده‌ی محدوده‌ای است که مدل با اطمینان ۹۰٪ انتظار دارد نمره واقعی دانش‌آموز در آن قرار گیرد. این بازه نسبت به پیش‌بینی مشاهده‌ی قبلی کمی پایین‌تر و گسترده‌تر است، که منعکس‌کننده‌ی اثر تجمعی مردودی‌ها و الکل در کاهش نمره و افزایش عدم قطعیت پیش‌بینی است. این تحلیل به ما کمک می‌کند تا نه تنها پیش‌بینی میانگین، بلکه دامنه‌ی احتمالی نمره را نیز در نظر بگیریم و تصمیمات آموزشی متناسب با ریسک و عدم قطعیت اتخاذ کنیم.





نمودار حاصل مقایسه توزیع نرمال و توزیع Student T با ۲ درجه آزادی را نشان می‌دهد. خط آبی نماینده توزیع نرمال است که اوج آن در مرکز ($x=0$) بیشترین احتمال را نشان می‌دهد و سرعت کاهش چگالی آن به سمت مقادیر دور از مرکز نسبتاً سریع است. در مقابل، خط قرمز نشان‌دهنده توزیع Student T است که در مرکز کمی پهن‌تر است و در دو انتهای توزیع (دم‌ها) وزن بیشتری دارد. این بدان معناست که مقادیر دور از میانگین، یا همان نقاط پرت، در این توزیع احتمال بیشتری دارند و بنابراین اثر آن‌ها روی مدل کمتر شدید و ناگهانی خواهد بود.

مزیت استفاده از توزیع Student T برای priors در مدل بیزی، به ویژه وقتی داده‌ها ممکن است نقاط پرت داشته باشند، مشخص می‌شود. با داشتن دم‌های سنگین‌تر، مدل نسبت به نمونه‌های دورافتاده مقاوم‌تر است و آن‌ها نمی‌توانند پارامترها را به شدت منحرف کنند، همان‌طور که ممکن است در توزیع نرمال اتفاق بیفتد. بنابراین، انتخاب توزیع Student T می‌تواند به ایجاد مدل بیزی پایدارتر و دقیق‌تر کمک کند، به‌خصوص در داده‌هایی با پراکندگی بالا یا نمونه‌های پرت.




نمودار **trace** حاصل از مدل بیزی با توزیع **Student T** برای احتمال خطا نشان‌دهنده نمونه‌گیری پارامترهای مدل از توزیع پسین است. هر ردیف از نمودار، یک پارامتر متفاوت را نشان می‌دهد و محور عمودی مقدار نمونه‌های پسین و محور افقی تعداد نمونه‌ها یا **iterations** را نمایش می‌دهد. خطوط موازی و نوسانات کم در **trace** نشان‌دهنده همگرایی خوب زنجیره‌های **MCMC** هستند، به‌طوری که زنجیره‌ها به خوبی فضای پارامترها را کاوش کرده و نمونه‌های مستقلی از توزیع پسین تولید کرده‌اند. وجود دو **trace** برای هر پارامتر نشان‌دهنده دو زنجیره **MCMC** مستقل است که برای بررسی همگرایی استفاده شده‌اند و اگر خطوط دو زنجیره به طور مشابه توزیع شوند، همگرایی قابل قبول است.

نمودار همچنین پارامترهای ویژه مدل **Student T** مانند **nu** و **sigma** را نشان می‌دهد **nu**. پارامتری است که شکل دم‌های توزیع **T** را کنترل می‌کند و مقادیر کمتر از ۳۰ نشان‌دهنده دم‌های سنگین‌تر و مقاومت بیشتر مدل نسبت به نقاط پرت است **Sigma**. نشان‌دهنده پراکندگی خطاها است. مشاهده نمونه‌های پایدار و نوسانات کم در این پارامترها تأیید می‌کند که مدل با توزیع **Student T** با موفقیت اجرا شده و می‌تواند نقاط پرت موجود در داده‌ها را بهتر مدیریت کند، در حالی که سایر پارامترهای رگرسیونی نیز توزیع‌های پسین منطقی و قابل تفسیر دارند.






نمودار forest که از نتایج مدل بیزی با توزیع Student T تولید شده است، نمایانگر برآوردهای پارامترهای مدل همراه با ناحیه اعتماد ۹۵٪ (HDI) است. هر نقطه در نمودار میانگین یا میانه پسین پارامتر را نشان می‌دهد و خط افقی مربوطه محدوده‌ی اطمینان ۹۵٪ آن پارامتر را نمایش می‌دهد. طول خطوط افقی بیانگر میزان عدم قطعیت در برآورد هر پارامتر است؛ خطوط طولانی‌تر نشان‌دهنده پارامترهایی هستند که مدل درباره مقدار واقعی آن‌ها کمتر مطمئن است و خطوط کوتاه‌تر نشان‌دهنده برآوردهای با دقت بالاتر هستند.

با نگاه دقیق به نمودار، پارامترهایی مانند failures و Dalc که اثر منفی بر نمره دانش‌آموز دارند، دارای خطوط افقی نسبتاً کوتاه هستند که بیانگر اطمینان نسبتاً بالا به تأثیر منفی آن‌هاست. در مقابل، پارامترهایی مانند studytime یا Medu ممکن است خطوط افقی طولانی‌تری داشته باشند که نشان می‌دهد مدل هنوز مقداری عدم قطعیت درباره شدت اثر آن‌ها دارد. استفاده از توزیع Student T باعث شده است که برآورد پارامترها نسبت به نقاط پرت مقاوم‌تر باشد و ناحیه‌های اطمینان HDI واقعی‌تر و قابل اعتمادتر باشند، بدون اینکه مقادیر پرت به شدت بر مدل تأثیر بگذارند.



نتایج ارزیابی مدل بیزی با توزیع Student T نشان می‌دهد که معیار RMSE برابر با ۲.۴۴۱۶ و MAPE برابر با ۰.۱۳۸۶ است. این مقادیر نشان می‌دهند که مدل جدید، میانگین خطای پیش‌بینی تقریباً ۲.۴ واحد در نمره دانش‌آموز و خطای نسبی میانه حدود ۱۳.۸٪ دارد. مقایسه با مدل قبلی که از توزیع نرمال استفاده می‌کرد نشان می‌دهد که استفاده از توزیع Student T اندکی خطا را کاهش داده و پیش‌بینی‌ها کمی دقیق‌تر شده‌اند، که این به دلیل مقاومت بالاتر مدل نسبت به داده‌های پرت و مقادیر غیرمعمول است.


در نمودارهای پراکندگی مشاهده می‌کنیم که نقاط تخمین زده شده با رنگ قرمز نزدیک‌تر به نقاط واقعی با رنگ آبی قرار دارند و بنابراین مدل توانسته توزیع داده‌ها را بهتر شبیه‌سازی کند. همچنین نمودارهای مقایسه RMSE و MAPE نشان می‌دهند که مدل جدید در میان سایر مدل‌ها عملکرد نسبتاً بهتری دارد. این تحلیل تأکید می‌کند که تغییر توزیع احتمال به Student T نه تنها باعث پایداری بیشتر در مواجهه با داده‌های پرت می‌شود، بلکه کیفیت پیش‌بینی‌های مدل را نیز بهبود می‌بخشد.




نمودار چگالی حاصل از پیش‌بینی مدل بیزی با توزیع Student T برای دانش‌آموزی با مشخصات داده‌شده نشان می‌دهد که تخمین‌های مدل حول یک مقدار مرکزی تجمع یافته‌اند، ولی در مقایسه با مدل نرمال، پراکندگی بیشتری دارند. این امر ناشی از خاصیت توزیع Student T است که به نمونه‌های پرت و مقادیر دور از میانگین وزن بیشتری می‌دهد و بنابراین مدل، عدم قطعیت بیشتری را در پیش‌بینی منعکس می‌کند. نمودار نشان می‌دهد که پیش‌بینی میانه نزدیک به مقدار واقعی نمره دانش‌آموز است، که بیانگر دقت خوب مدل در مرکز توزیع است.

همچنین بازه ۵٪ تا ۹۵٪ برای تخمین‌ها به خوبی عدم قطعیت مدل را نشان می‌دهد. این بازه نسبتاً گسترده‌تر نسبت به مدل نرمال است، که نشان می‌دهد مدل Student T هنگام مواجهه با مقادیر غیرمعمول یا داده‌های پرت، بیشتر محتاط است و دامنه احتمالات بیشتری را لحاظ می‌کند. این ویژگی باعث می‌شود پیش‌بینی‌ها انعطاف‌پذیرتر بوده و احتمال خطای شدید کمتر شود، که برای تصمیم‌گیری در شرایط واقعی آموزشی مزیت قابل توجهی است.

Density Plot for New Observation



Density Plot for New Observation



در این بخش، مدل رگرسیون خطی بیزی برای پیش‌بینی عملکرد دانش‌آموزان با استفاده از چندین ویژگی ورودی ساخته شد. به جای تعریف صریح یک مدل گرافیکی احتمالاتی که با متغیرهای پیوسته دشوار است، رویکردی مبتنی بر یادگیری ماشین اتخاذ شد و از کتابخانه (**bambi**) بر پایه (**PyMC**) برای ساخت مدل‌های احتمالاتی استفاده شد. این رویکرد امکان نمونه‌گیری از توزیع پسین پارامترها از طریق روش مارکوف چین مونت کارلو (**MCMC**) را فراهم کرد و به جای تولید یک نقطه تخمینی منفرد، توزیع احتمالی پارامترها و پیش‌بینی‌ها را در اختیار قرار داد. مقایسه توزیع‌های پیشین نرمال و **Student-t** نشان داد که هر دو توزیع نتایج منطقی ارائه می‌دهند، اما توزیع **Student-t** به دلیل دم‌های سنگین‌تر، در مواجهه با داده‌های پرت یا غیرگوسی عملکرد بهتری دارد. این ویژگی باعث می‌شود مدل نسبت به مقادیر غیرمعمول مقاوم‌تر باشد و تأثیر داده‌های پرت را محدود کند. با این حال، انتخاب توزیع پیشین مناسب همچنان یکی از چالش‌های اصلی مدل‌سازی بیزی است، زیرا توزیع پیشین می‌تواند بر نتایج پسین تأثیر قابل توجهی داشته باشد.

با افزایش حجم داده‌های آموزشی، تأثیر توزیع پیشین کاهش می‌یابد و مدل بیشتر مبتنی بر داده‌ها عمل می‌کند. به عبارت دیگر، با داده کافی، مدل‌های بیزی شبیه مدل‌های سنتی یادگیری ماشین می‌شوند که یادگیری آنها عمدتاً از داده‌ها ناشی می‌شود و نه از مفروضات قبلی. به همین دلیل، روش‌های بیزی در شرایط کم‌داده بسیار مفید هستند، زیرا می‌توانند با استفاده از دانش قبلی معقول، تخمین‌ها و تعمیم‌پذیری مدل را بهبود دهند.

در نهایت، مدل رگرسیون خطی بیزی مزایای قابل توجهی ارائه می‌دهد؛ از جمله ارائه توزیع پسین پارامترها، امکان سنجش عدم قطعیت پیش‌بینی‌ها و قابلیت کارایی در داده‌های محدود. حتی اگر عملکرد این مدل از نظر معیارهای **RMSE** و **MAPE** نسبت به مدل‌های یادگیری ماشین سنتی بهتر نباشد، مزایایی مانند تفسیرپذیری پارامترها، اندازه‌گیری‌های شهودی عدم قطعیت و


چارچوبی برای استدلال احتمالاتی را فراهم می‌کند. این ویژگی‌ها Bayesian Linear Regression را به ابزاری ارزشمند برای تحلیل‌های دقیق و سنجش ریسک در مسائل واقعی تبدیل می‌کنند.

3- Bayesian Deep Learning via Dropout (Bonus)

در این بخش، یک شبکه عصبی ساده با دو لایه پنهان و استفاده از Dropout برای رگرسیون ساخته شد تا رابطه بین ورودی‌های یک بعدی و خروجی سینوسی با نویز را مدل‌سازی کند. در طول آموزش، از MSE به عنوان تابع خطا و از SGD با L2 regularization برای بهبود تعمیم مدل استفاده شد. همان‌طور که در نتایج نشان داده شد، مقدار خطا در طی ۱۰,۰۰۰ تکرار به‌طور پیوسته کاهش یافته و از حدود ۱.۵۲۷۸ به ۰.۰۶۴۳ رسیده است که نشان‌دهنده همگرایی موفق شبکه و یادگیری الگوی اصلی داده‌ها است.

در مرحله پیش‌بینی، از نمونه‌گیری چندگانه با Dropout فعال استفاده نشده، اما میانگین پیش‌بینی‌های شبکه به‌دست آمد تا منحنی پیش‌بینی برای مقادیر بین -۲ و ۲ رسم شود. نقاط سیاه روی نمودار نشان‌دهنده داده‌های آموزشی نویزی هستند و منحنی آبی میانگین پیش‌بینی شبکه را نمایش می‌دهد. شبکه توانسته است به‌خوبی روند سینوسی داده‌ها را مدل کند، حتی با وجود نویز افزوده شده، که نشان‌دهنده قابلیت تعمیم نسبتاً خوب مدل است.


با این حال، نمودار همچنین نشان می‌دهد که در نقاطی که داده‌های آموزشی کمیاب هستند (مثلاً در گوشه‌های محدوده -۲ و ۲) انحراف شبکه نسبت به داده‌ها کمی بیشتر است. این موضوع معمولاً ناشی از عدم وجود اطلاعات کافی در این نواحی برای آموزش مدل است. استفاده از تکنیک‌های افزایش داده یا نمونه‌گیری با Dropout فعال در مرحله پیش‌بینی (MC Dropout) می‌توانست به تخمین عدم قطعیت و پوشش بهتر این نواحی کمک کند، اما در این مرحله، منحنی میانگین پیش‌بینی نشان‌دهنده تطابق خوب مدل با الگوی سینوسی اصلی داده‌ها است.



در این بخش، شبکه عصبی با استفاده از **MC Dropout** برای برآورد عدم قطعیت پیش‌بینی‌ها مورد استفاده قرار گرفت. با فعال نگه داشتن Dropout در مرحله پیش‌بینی و نمونه‌گیری ۱۰۰۰ بار، میانگین و انحراف استاندارد پیش‌بینی‌ها به دست آمد تا عدم قطعیت مدل در نقاط مختلف ورودی تخمین زده شود. نمودار آبی میانگین پیش‌بینی شبکه را نشان می‌دهد و منحنی قرمز نمایانگر تابع واقعی سینوسی است. نقاط سیاه داده‌های آموزشی را نمایش می‌دهند و نشان می‌دهد که مدل توانسته است روند اصلی داده‌ها را با دقت نسبتاً خوبی دنبال کند.

قسمت پررنگ آبی و سایه‌های مختلف آن نمایانگر فاصله اطمینان مدل هستند و نشان‌دهنده نواحی عدم قطعیت پیش‌بینی شبکه است. همان‌طور که مشاهده می‌شود، در نواحی که داده‌های


آموزشی کمتر هستند (نزدیک به -2 و 2)، نواحی اطمینان پهن تر هستند و نشان می دهند که مدل در این نقاط مطمئن تر نیست. این رفتار دقیقاً ویژگی مهم MC Dropout و تخمین عدم قطعیت در شبکه های عصبی است که امکان ارزیابی ریسک پیش بینی ها را فراهم می کند و به تصمیم گیری در شرایط داده های کم یا نویزی کمک می کند.




در این آزمایش، مدل شبکه عصبی کانولوشنی روی مجموعه داده MNIST مورد ارزیابی قرار گرفت و MC Dropout برای تخمین عدم قطعیت پیش بینی ها استفاده شد. هر تصویر از مجموعه تست در زوایای مختلف چرخانده شد و برای هر زاویه، پیش بینی های مدل با فعال بودن Dropout چندین بار (T) نمونه (انجام شد. میانگین پیش بینی ها برای تعیین برچسب نهایی

و انحراف استاندارد آن‌ها برای برآورد عدم قطعیت به کار گرفته شد. این کار نشان می‌دهد که چگونه مدل در مواجهه با تغییرات داده‌ها (چرخش تصویر) اعتماد خود را تنظیم می‌کند و نواحی شک و اطمینان پیش‌بینی‌ها به صورت کمی قابل مشاهده است.

نمودار حاصل شامل دو ردیف برای هر تصویر است؛ ردیف اول نشان‌دهنده تصاویر چرخانده شده با برچسب پیش‌بینی شده و ردیف دوم شدت عدم قطعیت مدل را با همان تصاویر نمایش می‌دهد. مشاهده می‌شود که وقتی تصویر در زاویه‌هایی که مدل کمتر با آن‌ها آموزش دیده است قرار می‌گیرد، عدم قطعیت پیش‌بینی‌ها افزایش می‌یابد و مدل کمتر مطمئن است. این تحلیل به ما امکان می‌دهد نقاط ضعف مدل را شناسایی کرده و از اطلاعات عدم قطعیت برای تصمیم‌گیری‌های محافظه‌کارانه‌تر یا جمع‌آوری داده‌های آموزشی اضافی استفاده کنیم.







4- Bayesian Neural Network via MCMC


در این آزمایش از روش MCMC نمونه برداری زنجیره مارکوف مونت کارلو برای تخمین توزیع پسین پارامترهای یک شبکه عصبی ساده استفاده شده است. در نمودار خروجی، داده های واقعی در مقابل مقادیر پیش بینی شده توسط مدل ترسیم شده اند. خط همبستگی ایده آل (یعنی جایی که پیش بینی دقیقاً برابر با مقدار واقعی است) به عنوان معیار مرجع عمل می کند. نقاطی که نزدیک به این خط قرار دارند نشان می دهند که مدل توانسته مقدار هدف را به درستی پیش بینی کند، در حالی که نقاطی که از خط فاصله گرفته اند معرف خطای پیش بینی هستند. این نمودار هم برای داده های آموزش و هم برای داده های تست رسم شده است تا قابلیت تعمیم مدل بررسی شود.

نتایج نشان می دهد که مدل توانسته با وجود ساختار ساده و تعداد نسبتاً محدود نمونه ها، همبستگی خوبی بین مقادیر واقعی و پیش بینی شده ایجاد کند. با این حال، وجود پراکندگی در برخی نقاط بیانگر آن است که عدم قطعیت در پیش بینی ها وجود دارد که در ذات رویکردهای بیزی نه تنها طبیعی، بلکه مفید است. این عدم قطعیت امکان می دهد تا علاوه بر پیش بینی مقدار خروجی، سطح اطمینان مدل نسبت به هر پیش بینی نیز ارزیابی شود. چنین رویکردی به ویژه در مسائل حساس یا داده های محدود بسیار کاربردی است، زیرا به تصمیم گیرنده این امکان را می دهد که به جای اعتماد مطلق به خروجی مدل، میزان اطمینان را نیز در نظر بگیرد.




نموداری که از این کد به دست می‌آید، یک سری زمانی از داده‌های واقعی در مقابل پیش‌بینی‌های مدل است. در این نمودار، مقادیر واقعی هدف (y_data) به صورت یک منحنی اصلی ترسیم شده و مقادیر پیش‌بینی‌شده مدل ($pred_y$) به شکل یک منحنی دیگر نمایش داده می‌شود. همچنین با فعال بودن گزینه‌ی $ci=True$ ، نواحی سایه‌دار یا باندهای عدم قطعیت پیرامون خط پیش‌بینی رسم می‌شوند که نشان می‌دهند مدل تا چه حد به تخمین خود اطمینان دارد. نزدیکی منحنی پیش‌بینی به مقادیر واقعی نشان‌دهنده‌ی توانایی مدل در یادگیری الگوهای موجود در داده‌های آموزشی است.

از طرفی، باندهای عدم قطعیت به تحلیل‌گر امکان می‌دهند تا ببینند مدل در کدام نقاط مطمئن‌تر و در کدام نقاط دچار تردید بیشتری است. معمولاً در بخش‌هایی که داده‌های آموزشی تراکم بیشتری دارند، باندها باریک‌تر و مدل مطمئن‌تر است، در حالی که در نواحی با داده‌های کمتر یا رفتار غیرخطی شدیدتر، باندهای عدم قطعیت پهن‌تر می‌شوند. این ویژگی ارزشمند است زیرا برخلاف مدل‌های کلاسیک صرفاً یک مقدار نقطه‌ای ارائه نمی‌دهد، بلکه طیفی از خروجی‌های ممکن را به همراه میزان اطمینان نشان می‌دهد.




نمودار حاصل، مقایسه‌ی سری زمانی داده‌های واقعی تست (**y_test**) با خروجی‌های پیش‌بینی‌شده مدل (**pred_y_test**) را نشان می‌دهد. خط اصلی بیانگر روند واقعی داده‌هاست و خط دیگر پیش‌بینی مدل را نمایش می‌دهد، در حالی که نوارهای اطراف خط پیش‌بینی همان باندهای عدم قطعیت (**confidence intervals**) هستند. اگر خطوط پیش‌بینی در بیشتر نقاط به خوبی روی داده‌های واقعی قرار گرفته باشند و باندهای عدم قطعیت باریک باشند، نشان می‌دهد که مدل تعمیم‌پذیری مناسبی روی داده‌های جدید دارد. در مقابل، اگر در برخی نواحی باندها پهن‌تر باشند یا اختلاف زیادی با داده واقعی دیده شود، بیانگر این است که مدل در آن نقاط نسبت به پیش‌بینی خود اطمینان کمتری دارد یا ساختار داده‌های تست با داده‌های آموزش تفاوت دارد.




در نمودار حاصل، توزیع پسین (**Posterior Distribution**) یک پارامتر از مدل شبکه عصبی بیزی نمایش داده می‌شود. این توزیع نشان می‌دهد که در طول نمونه‌گیری‌های MCMC، مقادیر پارامتر مورد نظر چگونه پراکنده شده‌اند. شکل هیستوگرام بیانگر میزان اطمینان مدل نسبت به

مقدار آن پارامتر است: اگر توزیع متمرکز و باریک باشد یعنی مدل در مقداردهی به آن پارامتر مطمئن است، در حالی که توزیع پهن یا چند قله‌ای بیانگر وجود عدم قطعیت بالاتر یا چندین حالت محتمل برای آن پارامتر است. همچنین مقدار میانگین پسین به عنوان تخمینی از مقدار واقعی پارامتر گزارش شده و در بالای نمودار چاپ می‌شود.




نمودار حاصل به صورت **Boxplot** توزیع مقادیر پسین وزن‌های شبکه عصبی را نشان می‌دهد. در این نمایش، برای هر وزن محدوده میانه، چارک‌ها و همچنین نقاط پرت قابل مشاهده است. اگر جعبه باریک و نزدیک به یک مقدار خاص باشد، بیانگر **قطعیت بالای مدل** نسبت به آن وزن است؛ در حالی که جعبه‌های پهن‌تر یا وجود نقاط پرت نشان‌دهنده **عدم قطعیت یا نوسان بیشتر** در مقدار آن پارامتر است. این تصویر دید کلی از تمام وزن‌های شبکه می‌دهد و به تحلیل‌گر کمک می‌کند بفهمد کدام وزن‌ها پایدار و معنادارند و کدام وزن‌ها احتمالاً نیازمند داده بیشتر یا معماری متفاوت شبکه هستند.



5- Bayesian Deep Learning via Dropout (Bonus)

نمودار حاصل از کد بالا، داده‌های مصنوعی تولیدشده توسط تابع `make_moons` را به صورت دوبعدی نمایش می‌دهد. در این تصویر، دو خوشه به شکل **هلال ماه** دیده می‌شود که هر کدام نشان‌دهنده یک کلاس از داده‌ها هستند. رنگ‌بندی نقاط (مثلاً آبی و قرمز) بیانگر برچسب‌های دودویی (۰ و ۱) است. این نوع داده به دلیل شکل غیرخطی و همپوشانی نسبی میان کلاس‌ها، یک چالش جالب برای مدل‌های یادگیری ماشین ایجاد می‌کند، زیرا جداسازی آن با یک خط یا مرز خطی ساده امکان‌پذیر نیست.


از سوی دیگر، استانداردسازی ویژگی‌ها پیش از نمایش باعث شده که داده‌ها دارای **مقیاس یکسان** باشند (میانگین صفر و واریانس یک)، که هم برای آموزش شبکه‌های عصبی ضروری است و هم در تصویر پراکندگی مناسب‌تری ایجاد می‌کند. این نمودار به خوبی نشان می‌دهد که برای حل این مسئله نیاز به مدل‌هایی با توانایی **یادگیری مرزهای تصمیم‌گیری غیرخطی** داریم؛ بنابراین چنین مجموعه داده‌ای گزینه‌ای عالی برای آزمایش معماری‌های ساده اما انعطاف‌پذیر مانند شبکه‌های عصبی یا روش‌های کرنل (مانند SVM با کرنل غیرخطی) است.



خروجی این کد، مسیر تکامل نمونه‌های به‌دست‌آمده از پارامترهای شبکه عصبی بیزی در طی فرآیند نمونه‌برداری همیلتونی (HMC) را نشان می‌دهد. برای نمایش بهتر، تمامی پارامترها توسط تحلیل مؤلفه‌های اصلی (PCA) به دو بعد کاهش داده شده‌اند. در نمودار، حرکت نمونه‌ها به‌صورت یک مسیر پیوسته نمایش داده شده است؛ نقطه‌ی سبز محل شروع زنجیره و نقطه‌ی


قرمز محل پایان نمونه‌گیری را مشخص می‌کند. این حرکت نشان‌دهنده تغییرات تدریجی پارامترها در طول شبیه‌سازی دینامیک همیلتونی است.

از منظر آماری، مشاهده می‌شود که نمونه‌ها پس از چندین تکرار در یک ناحیه پایدار متمرکز می‌شوند، که این موضوع نشانه‌ای از **تقریب همگرایی زنجیره به توزیع پسین** است. توزیع نسبتاً پیوسته‌ی نقاط حاکی از آن است که HMC توانسته فضای پارامتر را به‌طور کارآمد کاوش کند و از گیر افتادن در مینیمم‌های محلی اجتناب نماید. به بیان دیگر، این تصویر نشان می‌دهد که نمونه‌گیری از پسین مدل نه تنها متنوع است، بلکه روند آن به تدریج به یک الگوی پایدار نزدیک می‌شود که برای استنباط و پیش‌بینی در BNN مناسب خواهد بود.




خروجی این کد، مرز تصمیم‌گیری شبکه عصبی بیزی را در مجموعه داده‌ی تست به همراه نواحی عدم قطعیت مدل نمایش می‌دهد. در تصویر، رنگ‌ها نشان‌دهنده‌ی احتمال تعلق هر نقطه از فضا به کلاس ۱ هستند؛ به‌طوری‌که طیف آبی تا قرمز میزان احتمال را از نزدیک به صفر تا نزدیک به یک نمایش می‌دهد. نقاط داده‌ی تست نیز با رنگ‌های آبی و قرمز (بر اساس کلاس واقعی‌شان) روی نقشه پراکنده شده‌اند. این نمایش به‌خوبی نشان می‌دهد که مدل توانسته ساختار دو نیم‌دایره‌ای داده‌ی `make_moons` را یاد بگیرد و نواحی تصمیم‌گیری را با مرزهای نرم (به‌جای خطوط سخت) ترسیم کند.

از دید عملکرد، محاسبه‌ی دقت (**Accuracy**) نشان می‌دهد که **BNN** توانسته روی داده‌های تست پیش‌بینی قابل اعتمادی ارائه دهد. یکی از نکات مهم در این نمودار آن است که در مرزهای بین دو کلاس، رنگ‌ها به تدریج تغییر می‌کنند، که این خود بیانگر **عدم قطعیت پیش‌بینی** در این نواحی است. به عبارت دیگر، برخلاف مدل‌های قطعی، **BNN** علاوه بر پیش‌بینی کلاس، میزان اطمینان خود را نیز مشخص می‌کند. این ویژگی به‌ویژه در مسائل حساس (مانند پزشکی یا سیستم‌های ایمنی) اهمیت دارد، زیرا مدل می‌تواند نقاطی را که در آن‌ها اطمینان کمی دارد مشخص کند.



در بخش سمت چپ تصویر خروجی، میانگین پیش‌بینی (Predictive Mean) شبکه عصبی بیزی نمایش داده شده است. این بخش نشان می‌دهد که مدل با استفاده از نمونه‌گیری از توزیع پسین، چگونه مرز تصمیم‌گیری خود را در فضای ورودی ترسیم می‌کند. رنگ‌ها در این نمودار بیانگر احتمال تعلق نقاط به کلاس ۱ هستند (آبی برای احتمال پایین و قرمز برای احتمال بالا). علاوه بر این، مرز کلاس‌ها با یک خط سیاه مشخص شده که همان سطح احتمال ۰.۵ است. پراکندگی نقاط آموزشی روی این نقشه نیز نشان می‌دهد که مدل توانسته داده‌ها را به خوبی تفکیک کند و مرز تصمیم‌گیری مناسبی را بسازد.


در بخش سمت راست تصویر، نااطمینانی پیش‌بینی (Predictive Uncertainty) مدل نمایش داده شده است. رنگ‌های روشن‌تر نشان‌دهنده نواحی با واریانس بالا هستند؛ یعنی مناطقی که مدل در آن‌ها نسبت به پیش‌بینی خود مطمئن نیست. همان‌طور که انتظار می‌رود، این نواحی بیشتر در اطراف مرز تصمیم‌گیری و همچنین نقاطی که داده‌های آموزشی کمتر حضور دارند، دیده می‌شوند. این ویژگی مهم شبکه عصبی بیزی است که برخلاف مدل‌های قطعی، علاوه بر برآورد خروجی، میزان اعتماد خود به پیش‌بینی را نیز مشخص می‌کند. چنین قابلیت‌هایی کاربردهایی که ریسک خطا در آن‌ها بالاست (مانند پزشکی یا رانندگی خودکار) اهمیت زیادی دارد.



در تصویر خروجی حاصل از کد، تکامل پارامترهای شبکه عصبی در طی فرآیند نمونه‌گیری NUTS (No-U-Turn Sampler) به کمک کاهش ابعاد PCA به فضای دوبعدی نمایش داده شده است. مسیر ترسیم‌شده بیانگر تغییرات تدریجی نمونه‌ها در فضای پارامترهاست. نقطه سبز رنگ نشان‌دهنده نقطه شروع زنجیره مارکوف است و نقطه قرمز رنگ نشان‌دهنده موقعیت نهایی

پس از انجام همه نمونه‌گیری‌ها. حرکت منحنی‌مانند و پراکندگی مسیر نشان می‌دهد که الگوریتم در طول فرآیند به مرور فضای پارامتر را کاوش کرده است تا به ناحیه‌هایی با بیشترین احتمال پسین برسد.

از دید تحلیلی، وجود مسیرهای پرپیچ‌وخم در نمودار بیانگر این است که نمونه‌گیر NUTS توانسته به خوبی از گرفتار شدن در مینیمم‌های محلی اجتناب کند و فضای پارامترها را به طور کارآمد پوشش دهد. اگر حرکت زنجیره خیلی محدود یا بسیار خطی بود، نشانه ضعف در همگرایی یا کاوش ناکافی بود. در این تصویر، تغییرات تدریجی اما گسترده دیده می‌شود که نشان‌دهنده پایداری الگوریتم و دستیابی به تعادلی میان **اکتشاف** و **بهره‌برداری** در نمونه‌گیری است. این موضوع برای اطمینان از اعتبار نتایج بیزی بسیار حیاتی است.



6- Conclusion

در نتیجه، الگوریتم متروپلیس-هستینگز به عنوان یک روش مؤثر برای نمونه‌برداری از توزیع پسین عمل کرد. با اجرای زنجیره برای تعداد کافی تکرار و استفاده از تکنیک‌هایی مانند burn-in و thinning، مجموعه‌ای از نمونه‌ها به دست آمد که به خوبی توزیع پسین واقعی را نمایندگی می‌کنند و امکان تحلیل جامع‌تر عدم قطعیت پارامترها را فراهم می‌کنند.

این رویکرد مزیت روش‌های MCMC را در ارائه تصویری کامل و احتمالاتی به جای تکیه بر برآوردهای نقطه‌ای نشان می‌دهد. به‌ویژه در توزیع‌های پیچیده یا چندقله‌ای، استفاده از این نمونه‌ها امکان پیش‌بینی دقیق‌تر و درک بهتر از تغییرپذیری پارامترها را فراهم می‌کند و روش MCMC را به ابزاری قدرتمند برای استنتاج بیزی و کمی‌سازی عدم قطعیت تبدیل می‌کند.